

LingBot-VLA 2.0 lerobot 移植与加速: 全景报告

训练 / 推理最终配置、叠加工程方案与全部实测数字

代码:lerobot pr3967-combined 主测平台:8×A100-80GB 辅助:GB10 / 4×4090D(待测)

一句话定位 (2026-08-14 锁定,sdpa 全程保留,从未被否决):

训练 = sdpa(自动后端)+ bf16 + 稠密双 GEMM MoE(默认 512 阈值)

+ fused AdamW(optimizer_fused=true)+ 不开 grad-ckpt; 单卡 B=3 / DDP 每卡 B=2。

推理 = sdpa + bf16 + compile_predict_velocity

(max-autotune-

no-cudagraphs)+ compile_prefix + preprocess_device=cuda + num_steps=10, 一次性

bake 进 ckpt 的 config.json,rollout 只需 --policy.path。

工作对象:robbyant/lingbot-vla-v2 官方仓与 huggingface/lerobot PR #3967 移植版 (本地分支 pr3967-combined)。全部数字为真实 6B ckpt 实测; 主测时宿主机有 LIBERO eval 争抢 (load 21-57), 同条件前后对比有效, 绝对值偏保守, 干净机更快。口径: 推理 e2e = 预处理 + model forward(vision+prefix+10 步去噪)+ unapply; 训练 e2e = fwd + bwd + clip + optimizer.step。推理 workload A = robotwin 3 相机 480×640;B = SO101 单相机。训练数据集 = gpudat SO101(993 段 / 132k 帧 / 3 相机 512×512)。

1 推理

1.1 叠加工程方案 (按落地顺序)

保真度 (LIBERO drift vs fp32 参考, 阈值 2%):bf16 0.66-0.73%、dense MoE on/off 0.76%、C3 0.69%、C4 0.66%——全部同量级, 无劣化。

1.2 实验结果

e2e 加速 $3.9\times$ (对 eager)/ $2.55\times$ (对 compile); model-only $3.53\times/1.19\times$ 。LIBERO 真实帧路径 293 ms, 干净机估算约 250 ms。官方 README 的 130 ms@4090D claim 在 A100 无法复现 (最优 model-only 344 ms), 大概率是 sample_actions 的 print 计时口径;4×4090D 实测进行中, 结果补录。

2 训练

2.1 显存账本 (决定一切的前提)

可训练 5.81B / 冻结 0.42B。固定态 = bf16 参数 11.6GB + 梯度 10.8GB + AdamW m+v fp32 43.3GB(54%)= 65.7GB; 激活约 10GB/样本。optimizer 状态才是大头, 压激活是错杠杆。

表 1: 推理优化栈: 每一项为什么做、怎么起效、实测结果 (A100)

方案	原因	原理	结果
sdpa + bf16; 去噪循环 不变量外提;MoE 去 同步	PR 基线 eager, 每步去噪 重复算不变量、MoE 有隐 式同步	fused attention kernel; 不变量提 到循环外; 去掉 host 端同步	1039.5 → 951.9 ms(-8.4%)
compile_predict_ velocity (max-autotune- no-cudagraphs)	10 步去噪 = 10 次小图发 射,launch 开销主导	torch.compile 把去噪步骤融成 整图	→ 699.5 ms(-32.7%)
稠密双 GEMM MoE (moe_dense_ max_tokens=512)	小 token 数下 per-expert 循环 kernel 发射多、 GEMM 利用率低	token 数 ≤512 时改走两次大 GEMM 的稠密等价计算	robotwin 967.4 → +compile 398.5 ms(-73.3% vs eager 基线);loss 一致到 9×10^{-7}
compile_prefix(C3)	vision+prefix 每次推理重 算且未编译	prefix KV fill 一并编译 (model 口 径)	-20%(253–269 ms 区间)
preprocess_device =cuda(C4)	CPU 预处理占 e2e 近一 半 (668 ms / 1705 ms)	图像 resize/normalize 移到 GPU, 预处理 -62%	e2e 约 300 ms(SO101, 全程 -79%)
bake 固化五开关	推理开关走 CLI 易漏、训 练侧又必须是默认关	写进 ckpt config.json,from_pretrained 自动生效	rollout 零 flag; 一次性编译 43.7 s 后稳态 258 ms

表 2: 推理: 官方 upstream vs 本分支 (同权重,robotwin 3 相机,10 步去噪)

配置	e2e (ms)	预处理	model
官方 eager(README 默认)	1705.0	668.1	1020.7
官方 use_compile	1113.0	752.3	344.2
本分支优化栈	436.6	147.8	288.8

表 3: 推理 attention 消融 (锁定栈内,compile+prefix+GPU 预处理,itors=10)

组合	e2e (ms)	Δ	结论
sdpa + bf16(推荐)	252.9	—	推荐
eager + bf16	276.8	+9.4%	慢
eager + fp32(上游原始)	251.9	-0.4%(噪声内)	compile 下不掉速; 训练慢
sdpa + fp32	289.7	+14.5%	最差, 谁也别用

2.2 叠加工程方案

表 4: 训练优化栈: 每一项为什么做、怎么起效、实测结果 (A100-80GB)

方案	原因	原理	结果
稠密双 GEMM MoE	同推理,per-expert 循环在训练 batch 下同样低效	双 GEMM 稠密等价	B=4 fwd+bwd 2807.1 → 1501.3 ms(-46.5%),loss 一致到 9×10^{-7}
fused AdamW (optimizer_fused=true)	参数逐个 python 循环更新	单 kernel 融合	-5.4% ,loss 逐位一致
sdpa + bf16 (不换 eager)	bench 曾显示 eager 快 6.9% 省 10GB	bench 是相同样本平铺的假象; 真实变长序列下 mem-efficient sdpa 更优	300 步真实 A/B:sdpa 0.978 s/65.7GB vs eager 0.999 s/68.5GB,eager B=4 OOM
不开 grad-ckpt	省的是不缺钱的激活	重算换显存, 固定态 65.7GB 纹丝不动	+38% 慢, 否决
batch 选择	80GB 装得下多少激活	65.7GB 固定 + ~10GB/样本	单卡 B=3(72.0GB);DDP allreduce +11GB/卡 ⇒ 每卡 B=2

2.3 实验结果

表 5: 单卡训练吞吐排序 (e2e = fwd+bwd+clip+step,robotwin 3 相机)

组合	step (ms)	samples/s	峰值显存	结论
B=3 bf16 fused(推荐)	1509.7	1.99	72.0GB	冠军
B=4 + 8bit AdamW(bnb)	2159.9	1.85	73.5GB	可行但更慢
B=2 fused	1137.3	1.76	—	基线
B=4 + grad-ckpt	—	更低	28.7GB	+38% 慢, 否决

e2e 总收益:PR 原版 B=2 2378.1 ms → foreach 1202.0 → **fused 1137.3 ms (-52%,2.09×)**, 三者 loss 0.528622 一致到 10^{-6} 。

多卡 (社区标准 accelerate launch + lerobot-train, batch_size 为每卡语义):1 卡 1.97 s/step → 2 卡 1.00 s(4.0 samples/s) → 4 卡 1.00 s(**8.0 samples/s**),2→4 完美线性。30k 步: 单卡 B=3 约 12.6 h,4 卡约 **8.3 h**。

表 6: 训练 attention 长训 A/B(300 步,gpudad 真实数据,2026-08-14)

臂	updt_s 稳态	峰值显存	loss 曲线
LA sdpa+bf16 B=3	0.978	65.7GB	完全等价
LB eager+bf16 B=3	0.999(+2.2%)	68.5GB(+2.9GB)	(max Δ ≈ 0.012)
LC eager+bf16 B=4	OOM	79.3/80GB	bench 说能跑, 真实不行

对官方 upstream 训练: 官方单卡 80GB 完全跑不了 (muon fp32 master+ 动量约 74GB,micro=2 + grad-ckpt 仍 OOM, 官方设计为 32 卡 fsdp2); 官方 4 卡 fsdp2 micro=2/卡 (global 8) 稳态 2.999 s/step = 0.67 samples/s/GPU; 本分支单卡 2.35 samples/s(fwd+bwd)≈ 官方 per-GPU 吞吐的 **3.5×**。口径声明: 官方含 MoGe/DINO-video 蒸馏前向支线, 移植版没有该开销。

3 负面结果 (全部被实测否决的路)

表 7: 否决清单: 不是 sdpa, 是这些东西

被否决项	证据 / 原因
显式设 sdpa_backend(任何值)	CUDNN:bf16+bool mask+GQA 下 backward 1222/1267 梯度 NaN,step 1 即 grdn:nan(前向 parity 完全正常, 不足为据); EFFICIENT:No available kernel
eager 训练	bench 假象 (相同样本平铺);300 步真实 A/B:+2.2% 慢、+2.9GB、B=4 OOM
attention_fp32	+8-14% 慢, 数值无收益
fp16 推理	launch-bound 无收益 (294.7 vs bf16 278.9 ms) 且 LIBERO drift 3.33% 超阈值
flex_cached 训练	+75% 慢
grad-ckpt(B≤4)	+38% 慢, 省的是不缺钱的显存

4 最终结论

训练:sdpa(自动后端)+ bf16 + 稠密 MoE + fused AdamW + 不开 grad-ckpt, 单卡 B=3(1.99 samples/s,72GB)/ DDP 每卡 B=2(4 卡 8.0 samples/s,30k 步约 8.3 h)。相对 PR 原版 **2.09**×, 相对官方 per-GPU **3.5**×。

推理:sdpa + bf16 + compile(max-autotune-no-cudagraphs)+ compile_prefix + GPU 预处理 + num_steps=10,bake 进 ckpt。相对官方 eager **3.9**× (1705.0 → 436.6 ms),SO101 单相机约 300 ms。

- 配套文档 (均在 docs/accel/):
- 操作手册:lingbot_vla_train_rollout_commands.md (lerobot-train / lerobot-rollout 命令全文);
 - 开关逐项启动验证 (13 臂,11 通过):lingbot_vla_switch_table.pdf;
 - reBot B601 实操:lingbot_vla_rebot_guide.pdf;
 - 社区英文 quickstart:
lingbot_vla_v2_community_quickstart.md。

5 已知边界与后续项

- 全部绝对时延为污染环境 (load 21-57) 实测, 干净机更快; 相对结论不受影响。
- 8 卡 DDP 数字为 2/4 卡线性外推, 真 8 卡验证待 GPU 0-3 释放。
- 训练侧进一步候选:compile 训练整图 (-1020%, 攻坚)、fsdp2 固定态分片 (24GB 卡必需)。
- 4×4090D 实测 (官方 claim 平台) 进行中, 结果补录。

参考与产物 分支 pr3967-combined(关键 commit:f2ff2ca5 稠密 MoE、569929b8 C3、21ef4187 C4、e23a03f5 sdpa_backend+fused);A100 数据目录 ~/accel-bench/(train_e2e/、switch_smoke/、long_ab/ 等); 备份 ~/accel-bench/backups/(git bundle + STATE.md)。